

Étude de Modélisation Énergétique des Logements du Rhône (69)

Application *DPE Vision IA*

1 Contexte et Objectifs

1.1 Pourquoi cette étude ?

Le **Diagnostic de Performance Énergétique (DPE)** est devenu un critère décisif pour :

- la valeur d'un bien immobilier,
- la mise en location,
- l'obligation de rénovation thermique.

L'accès à ces informations reste limité : il nécessite un audit thermique officiel (payant), et les données ne sont pas toujours accessibles au grand public.

Objectif général du projet : Fournir à tout ménage du département du Rhône une estimation fiable de sa **classe énergétique (A→G)** et de sa **consommation annuelle**, sans audit complet.

1.2 Objectif technique

Nous avons conçu une chaîne complète :

1. **Collecte et fusion de données réelles** : ADEME (étiquettes DPE officielles) et Enedis (consommations IRIS).
2. **Préparation et feature engineering**.
3. **Entraînement de modèles de Machine Learning**.
4. **Exposition temps réel** via :
 - API FastAPI,
 - interface Streamlit (cartographie et simulation),
 - interprétation automatique par LLM (Mistral).

1.3 Cas d'usage métier

L'utilisateur peut décrire son logement (surface, année, isolation, énergie de chauffage...) et obtenir :

- une **étiquette DPE prédite**,
- une **consommation estimée en kWh/m²/an**,
- une **explication des facteurs principaux** affectant la performance.

Ce projet dépasse la modélisation académique : il constitue un **prototype d'aide à la décision énergétique locale**.

2 Données et Préparation

2.1 Sources de données

- **ADEME – DPE Rhône (69)** : 358 302 logements, avec caractéristiques thermiques et étiquettes officielles.
- **Enedis – Consommations réelles** : données agrégées par zone IRIS.
- **Contexte climatique et géographique** : rattachement des logements à leur zone climatique et IRIS.




FIGURE 1 – Flux de traitement et fusion ADEME × Enedis

2.2 Table des jeux de données utilisés

Source	Fichier	Origine	Description
ADEME	df_adem_existant_69.csv	data.ademe.fr	Diagnostics existants 69.
ADEME	df_adem_neuf_69.csv	data.ademe.fr	Diagnostics logements neufs.
Enedis IRIS	df_enedis_69.csv	data.enedis.fr	Consommations agrégées.
IRIS Rhône	IRIS_RHONE.geojson	data.gouv.fr	Contours géographiques.
Fusion	df_adem_enedis_iris_69.csv	—	Base enrichie pour la modélisation.

2.3 Nettoyage des données

Les règles de filtrage appliquées :

- Suppression des valeurs physiques aberrantes (consommation $> 50\,000$ kWhEP/an, surface $< 9\text{ m}^2$ ou $> 500\text{ m}^2$).
- Filtrage des années de construction ($1800 < \text{annee} < 2025$).
- Exclusion des enregistrements avec valeurs manquantes critiques.

Résultat : un dataset propre, cohérent et représentatif du parc résidentiel.

2.4 Analyse exploratoire (EDA)

L'EDA met en évidence :

- Distribution asymétrique de la consommation (nécessitant une transformation logarithmique).
- Concentration DPE sur les classes C–E.
- Corrélations fortes entre certaines variables énergétiques (GES, conso totale, coût).




FIGURE 2 – Distribution de la consommation énergétique totale (kWhEP/an)




FIGURE 3 – Distribution des étiquettes DPE dans le Rhône (69)

2.5 Feature Engineering

Les principales variables dérivées :

- **Âge du bâtiment** : $anciennete = 2025 - annee_construction$
- **Score d'isolation global** : moyenne pondérée murs/toiture/menuiseries.
- **Énergie regroupée** : familles principales (électricité, gaz, fioul...).
- **Volume du logement** : $surface \times hauteur$
- **Contexte IRIS** : ajout des consommations moyennes locales (Enedis).




FIGURE 4 – Rattachement géospatial des logements du Rhône aux zones IRIS

2.6 Regroupement des classes DPE

Les classes A→G ont été regroupées en 5 catégories équilibrées :

$$A_B, C, D, E, F_G$$




FIGURE 5 – Distribution des classes DPE regroupées

3 Méthodologie de Modélisation

3.1 Vue d'ensemble

Trois modèles complémentaires ont été développés :

1. **Modèle 1 – Classification directe DPE** : à partir des caractéristiques physiques.
2. **Modèle 2 – Régression consommation (kWh/m²/an)**.
3. **Modèle 3 – Classification DPE augmentée** : intégrant la consommation réelle ou prédite.

3.2 Étapes de modélisation

Prétraitement :

- Split 80/20, validation croisée stratifiée ($k=5$),
- Encodage numérique (RobustScaler) et catégoriel (OneHotEncoder),
- Gestion du déséquilibre via SMOTE.

Algorithmes testés :

- RandomForestClassifier
- DecisionTreeClassifier
- KNN
- LogisticRegression

3.3 Modèle DPE (classification directe)




FIGURE 6 – Matrice de confusion – Modèle 1 (avec consommation)

Résultats :

- Accuracy $\approx 97\%$, F1 $\approx 95\%$.
- Corrélation forte entre `conso_m2` et la cible DPE ($r = 0.87$).

Décision : suppression des variables de consommation pour éviter les fuites de données.

3.4 Modèle DPE sans consommation

Pipeline identique, sans les variables énergétiques. **Performance** : Accuracy $\approx 80\%$, F1 $\approx 77\%$.




FIGURE 7 – Matrice de confusion – Modèle DPE sans consommation

3.5 Modèle de Régression – Prédiction de la consommation

Cible : conso_m2 (log-transformée).

Algorithmes testés :

- RandomForestRegressor
- XGBoost
- LightGBM

Modèle	RMSE	MAE	R ²
RandomForest	0.254	0.170	0.748
XGBoost	0.262	0.196	0.731
LightGBM	0.262	0.196	0.731

RandomForest est retenu pour sa robustesse et sa simplicité.

3.6 Validation et reproductibilité

- Validation croisée (5-fold) pour évaluer la variabilité.
- `random_state=42` fixé pour la reproductibilité.
- Sauvegarde des modèles compressés (.joblib) pour l'API.

	Nom du modèle	Type de modèle	Nb total de features	Nb features numériques	Nb features catégorielles	Profondeur max	Nb arbres (si forêt)	max_features	min_samples_split	min_samples_leaf	Random state
0	DPE sans conso	RandomForestClassifier	39	6	6	nan	300	sqrt	2	1	42
1	DPE avec conso	RandomForestClassifier	40	7	6	25.000000	300	sqrt	5	1	42
2	Consommation (régression)	RandomForestRegressor	39	6	6	25.000000	400	sqrt	5	1	42

FIGURE 8 – Fiches comparatives des modèles entraînés

4 Résultats et KPI

4.1 Modèle 1 – DPE direct

Accuracy = 79%, F1 = 76.9% (bon repérage des classes extrêmes).

4.2 Modèle 2 – Consommation

$R^2 = 0.872$, RMSE = 28.4, MAE = 21.7, MAPE = 11.2%.

4.3 Modèle 3 – DPE augmenté

- Mode supervisé : Accuracy = 99%.
 - Mode chaîné : Accuracy = 67%.
- Performances stables sur les folds : pas de surapprentissage notable.

5 Interprétation via Mistral LLM

Le module **Mistral AI** permet une interprétation textuelle automatique :

- identification des facteurs clés (isolation, énergie, âge du logement...),
- génération de recommandations personnalisées,
- vulgarisation du diagnostic pour le grand public.

6 Conclusion

Cette étude a permis :

- la création d'un pipeline complet de modélisation énergétique territoriale ;
- la mise au point de trois modèles ML robustes et complémentaires ;
- leur intégration dans une application Streamlit interactive ;
- l'ajout d'un module d'interprétation automatique via Mistral LLM.

Le système **DPE Vision IA** constitue une preuve de concept aboutie pour une **évaluation énergétique automatisée et explicable** à l'échelle départementale.