

Étape 04 — Analyse exploratoire et visualisation (EDA)

Objectifs du notebook

L'objectif de cette étape est de comprendre les caractéristiques principales du parc de logements et d'identifier les tendances qui influencent la performance énergétique.

Plus précisément :

1. Décrire la structure du dataset
 - Dimensions, types de variables, valeurs manquantes restantes
2. Analyser les distributions principales
 - Surface, consommation, émissions de GES, année de construction
3. Visualiser les relations clés
 - `etiquette_dpe` vs `conso_5_usages_ep`
 - `type_batiment` vs `emission_ges_5_usages`
 - `annee_construction` vs `consommation`
4. Comparer les logements neufs vs existants
 - grâce à la variable `type_logement_source`
5. Identifier les variables les plus corrélées
 - pour guider la future modélisation ML (classification DPE)
6. Produire des graphiques clairs et interprétables
 - Histogrammes, boxplots, scatterplots, heatmap de corrélation

01. Import

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

```
import plotly.express as px

# Configuration d'affichage
pd.set_option("display.max_columns", 40)
sns.set(style="whitegrid")

# Chargement des données nettoyées
df = pd.read_csv("../data/df_adem_cleaned_69.csv", low_memory=False)
print(f"Dataset chargé : {len(df):,} lignes - {len(df.columns)} colonnes")
df.head(3)
```

Dataset chargé : 427,661 lignes - 35 colonnes

Out [1]:

	conso_5_usages_ep	emission_ges_5_usages	nom_commune_ban	type_logement_source	cout_total_5_usages	etiquette_ges	methode_applic
--	-------------------	-----------------------	-----------------	----------------------	---------------------	---------------	----------------

0	28727.8	8507.0	SAINT-CLÉMENT- DE-VERS	EXISTANT	2693.3	E	DPE INDI
---	---------	--------	---------------------------	----------	--------	---	-------------

1	47440.8	6325.7	PROPIÈRES	EXISTANT	2860.4	E	DPE INDI
---	---------	--------	-----------	----------	--------	---	-------------

2	41945.9	1379.9	SAINT-BONNET- DES-BRUYÈRES	EXISTANT	2619.4	C	DPE INDI
---	---------	--------	-------------------------------	----------	--------	---	-------------

02. Aperçu général & statistiques globales

```
In [2]: # Info rapide sur la structure
df.info()

# Statistiques de base
df.describe().T.head(15)
```

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 427661 entries, 0 to 427660

Data columns (total 35 columns):

#	Column	Non-Null Count	Dtype
0	conso_5_usages_ep	427661 non-null	float64
1	emission_ges_5_usages	427661 non-null	float64
2	nom_commune_ban	427661 non-null	object
3	type_logement_source	427661 non-null	object
4	cout_total_5_usages	427661 non-null	float64
5	etiquette_ges	427661 non-null	object
6	methode_application_dpe	427661 non-null	object
7	type_energie_principale_chauffage	427661 non-null	object
8	code_region_ban	427661 non-null	float64
9	conso_refroidissement_ep	427661 non-null	float64
10	qualite_isolation_murs	427661 non-null	object
11	coordonnee_cartographique_y_ban	427661 non-null	float64
12	type_batiment	427661 non-null	object
13	numero_dpe	427661 non-null	object
14	date_fin_validite_dpe	427661 non-null	object
15	inertie_lourde	427661 non-null	float64
16	conso_ecs_ep	427661 non-null	float64
17	annee_construction	427661 non-null	float64
18	nombre_niveau_logement	427661 non-null	float64
19	version_dpe	427661 non-null	float64
20	modele_dpe	427661 non-null	object
21	type_installation_ecs	427661 non-null	object
22	code_departement_ban	427661 non-null	float64
23	surface_habitable_logement	427661 non-null	float64
24	type_installation_chauffage	427661 non-null	object
25	hauteur_sous_plafond	427661 non-null	float64
26	conso_chauffage_ep	427661 non-null	float64
27	isolation_toiture	427661 non-null	float64
28	etiquette_dpe	427661 non-null	object
29	coordonnee_cartographique_x_ban	427661 non-null	float64
30	code_postal_ban	427661 non-null	int64
31	zone_climatique	427661 non-null	object
32	qualite_isolation_menuiseries	427661 non-null	object
33	date_reception_dpe	427661 non-null	object
34	emission_ges_chauffage	427661 non-null	float64

```
dtypes: float64(18), int64(1), object(16)
memory usage: 114.2+ MB
```

Out[2]:


	count	mean	std	min	25%	50%	75%	max
conso_5_usages_ep	427661.0	1.250364e+04	8436.508141	303.5	6695.00	10455.50	15883.90	93511.80
emission_ges_5_usages	427661.0	1.512356e+03	1530.657752	0.0	432.60	1000.60	2067.20	9999.90
cout_total_5_usages	427661.0	1.082425e+03	668.197987	38.3	633.00	928.50	1346.60	8987.30
code_region_ban	427661.0	8.400000e+01	0.000000	84.0	84.00	84.00	84.00	84.00
conso_refroidissement_ep	427661.0	2.222071e+01	161.954212	0.0	0.00	0.00	0.00	4954.90
coordonnee_cartographique_y_ban	427661.0	6.511941e+06	234933.546097	0.0	6516710.45	6519353.91	6521564.96	6579322.02
inertie_lourde	427661.0	1.958257e-01	0.396835	0.0	0.00	0.00	0.00	1.00
conso_ecs_ep	427661.0	2.970874e+03	1375.705683	0.0	1907.60	2651.90	3905.50	9999.80
annee_construction	427661.0	1.982031e+03	25.603212	1460.0	1973.00	1980.00	1994.00	2025.00
nombre_niveau_logement	427661.0	1.230893e+00	0.897948	1.0	1.00	1.00	1.00	10.00
version_dpe	427661.0	2.216546e+00	0.287711	1.0	2.20	2.30	2.40	2.50
code_departement_ban	427661.0	6.899993e+01	0.047404	38.0	69.00	69.00	69.00	69.00
surface_habitable_logement	427661.0	6.554099e+01	33.364205	9.0	44.20	63.00	79.80	604.80
hauteur_sous_plafond	427661.0	2.584333e+00	0.232711	2.0	2.50	2.50	2.50	5.00
conso_chauffage_ep	427661.0	8.430365e+03	7561.958430	0.0	3290.50	6248.20	11177.80	79976.50

Distribution des variables principales

Consommation énergétique globale

```
In [5]: plt.figure(figsize=(8,5))
sns.histplot(df["emission_ges_5_usages"], bins=50, kde=True)
plt.title("Distribution des émissions de GES (kgCO2/an)")
plt.xlabel("Émissions GES (kgCO2/an)")
plt.show()
```

```
c:\Users\km_sa\AppData\Local\Programs\Python\Python310\lib\site-packages\IPython\core\pylabtools.py:152: UserWarning: Glyph 8322 (\N{SUBSCRIPT TWO}) missing from current font.
  fig.canvas.print_figure(bytes_io, **kw)
```



```
In [29]: df["emission_ges_5_usages"].skew()
```

Out [29]: 2.0091809126334534

Interprétation

La distribution est **fortement asymétrique à droite**, indiquant qu'une grande majorité des logements ont de **faibles émissions de gaz à effet de serre**, tandis qu'une minorité présente des valeurs beaucoup plus élevées.


Ce profil est typique des données énergétiques : la plupart des bâtiments sont modérément performants, alors que quelques-uns sont très énergivores.

Implications pour la modélisation :

- Une **transformation logarithmique** pourra être envisagée pour cette variable afin de réduire la variance et rendre la distribution plus proche d'une loi normale.

Émissions GES

```
In [4]: plt.figure(figsize=(8,5))
sns.histplot(df["conso_5_usages_ep"], bins=50, kde=True)
plt.title("Distribution de la consommation énergétique totale (kWhEP/an)")
plt.xlabel("Consommation totale (kWhEP/an)")
plt.show()
```



Interprétation – Distribution de la consommation énergétique totale (kWhEP/an)

La distribution est **fortement asymétrique à droite**, avec une majorité de logements dont la consommation énergétique se situe entre **5 000 et 20 000 kWhEP/an**.

Les valeurs extrêmes au-delà de 50 000 kWhEP/an sont rares et représentent des **logements très énergivores** ou des **erreurs de mesure**.

Cette forme en « longue traîne » est caractéristique des consommations réelles : la majorité des bâtiments ont une consommation modérée, tandis qu'une minorité consomme énormément.

Implications pour la modélisation :

- Une transformation logarithmique ou une normalisation peut être utile pour cette variable afin de stabiliser la variance.
 - `conso_5_usages_ep` servira directement comme variable cible pour la tâche de régression et sera aussi un indicateur clé pour la prédiction de la classe DPE.
 - `emission_ges_5_usages` semble fortement corrélée à la consommation énergétique, elle sera donc un bon indicateur complémentaire pour prédire la classe énergétique (`etiquette_dpe`).
 - Cette distribution confirme l'existence de fortes disparités énergétiques dans le parc immobilier, à explorer selon le type de bâtiment, la zone climatique et l'année de construction.
-

Répartition des classes DPE et GES

```
In [45]: palette_dpe = {"A": "#009933", "B": "#33CC33", "C": "#CCFF33", "D": "#FFFF00", "E": "#FF9900", "F": "#FF3300", "G": "#CC0000"}
```

```
In [46]: fig, axes = plt.subplots(1, 2, figsize=(12,5))

sns.countplot(x="etiquette_dpe", data=df, order=list("ABCDEFGG"),
              ax=axes[0], palette=palette_dpe)
axes[0].set_title("Distribution des classes DPE")

sns.countplot(x="etiquette_ges", data=df, order=list("ABCDEFGG"),
              ax=axes[1], palette=palette_dpe)
axes[1].set_title("Distribution des classes GES")

plt.show()
```




```
C:\Users\km_sa\AppData\Local\Temp\ipykernel_26148\752804637.py:3: FutureWarning:
```

```
Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.
```

```
C:\Users\km_sa\AppData\Local\Temp\ipykernel_26148\752804637.py:7: FutureWarning:
```

```
Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.
```



Interprétation – Répartition des classes DPE et GES

Les deux distributions présentent une forte concentration autour des classes C et D, qui représentent la majorité du parc immobilier du département 69.

Les classes A et B (logements très performants) ainsi que F et G (logements très énergivores) sont minoritaires.


Cette répartition correspond à la réalité nationale : la majorité des bâtiments se situent au milieu du classement énergétique.

Implications pour la modélisation :

- Le jeu de données est **déséquilibré** : les classes extrêmes (A, B, F, G) sont sous-représentées.
- Le modèle devra être évalué non seulement par **accuracy**, mais aussi via des métriques robustes comme le **F1-score par classe**.
- Cette visualisation valide la qualité de la donnée : pas d'anomalie dans l'ordre des classes, cohérence entre DPE et GES.

Analyse croisée : DPE vs consommation

```
In [7]: plt.figure(figsize=(10,5))
sns.boxplot(x="etiquette_dpe", y="conso_5_usages_ep", data=df, order=list("ABCDEFGG"))
plt.yscale("log")
plt.title("Distribution de la consommation selon la classe DPE (échelle log)")
plt.show()
```



Interprétation – Relation entre la classe DPE et la consommation énergétique

On observe une **progression claire de la consommation énergétique** entre les classes **A** et **G**.

Les logements les plus performants (A–B) consomment nettement moins d'énergie que les classes inférieures, tandis que les classes **E** à **G** présentent des consommations médianes beaucoup plus élevées.

Cette évolution régulière valide la cohérence des données : le DPE traduit bien la performance énergétique réelle des bâtiments.

L'échelle logarithmique permet de **visualiser les écarts importants** entre classes tout en atténuant l'effet des valeurs extrêmes.

Implications pour la modélisation :

- La variable `etiquette_dpe` est **étroitement liée à la consommation totale** (`conso_5_usages_ep`).
 - Les classes présentent des distributions **largement distinctes**, ce qui facilitera la séparation des catégories par un modèle supervisé.
-


Analyse temporelle : année de construction

```
In [47]: plt.figure(figsize=(10,5))
sns.scatterplot(
    x="annee_construction",
    y="conso_5_usages_ep",
    data=df,
    alpha=0.3,
    color="#1f77b4"
)

plt.title("Consommation énergétique selon l'année de construction (1800-2025)")
plt.xlabel("Année de construction")
plt.ylabel("Consommation totale (kWhEP/an)")

# Limites de l'axe X et graduation tous les 20 ans
plt.xlim(1800, 2025)
plt.xticks(range(1800, 2026, 20))

plt.show()
```



Interprétation – Consommation énergétique selon l'année de construction

On observe une **tendance générale à la baisse de la consommation énergétique** pour les bâtiments construits après les années 2000.

Les constructions anciennes (avant 1980) présentent une **grande dispersion des consommations**, souvent très élevées, traduisant la **faible qualité d'isolation** et l'absence de normes thermiques à l'époque.

Implications pour la modélisation :

- L' `annee_construction` est une **variable explicative essentielle** de la performance énergétique et devra être conservée dans le modèle.


- La tendance décroissante confirme qu'il existe une **corrélation négative** entre l'âge du bâtiment et sa consommation.
 - Il serait pertinent d'ajouter une **catégorisation par période** (avant 1975, 1975–2005, après 2005)
-


Comparaison : logements neufs vs existants

```
In [9]: plt.figure(figsize=(8,5))
sns.boxplot(x="type_logement_source", y="conso_5_usages_ep", data=df)
plt.title("Comparaison de la consommation selon le type de logement (neuf vs existant)")
plt.xlabel("Type de logement")
plt.ylabel("Consommation totale (kWhEP)")
plt.show()

sns.countplot(x="etiquette_dpe", hue="type_logement_source", data=df, order=list("ABCDEFGF"))
plt.title("Distribution DPE selon le type de logement")
plt.show()
```

Comparaison de la consommation selon le type de logement (neuf vs existant)





Interprétation – Comparaison entre logements neufs et existants

Consommation énergétique

Les logements **neufs** présentent une **consommation énergétique médiane nettement inférieure** à celle des logements existants. La dispersion est également beaucoup plus faible, signe d'une **meilleure maîtrise énergétique** grâce aux réglementations thermiques récentes (RT2012, RE2020). À l'inverse, les logements **anciens** montrent des consommations très variables, certaines atteignant des valeurs extrêmes liées à de **mauvaises performances d'isolation** ou à des systèmes de chauffage vétustes.

Distribution des classes DPE

La deuxième figure confirme cette tendance :


- Les logements **neufs** sont majoritairement classés **B** ou **C**, correspondant à une bonne efficacité énergétique.
- Les logements **existants** se concentrent sur les classes **C** à **E**, avec une part significative de **F** et **G**, traduisant un parc ancien énergivore.

Implications pour la modélisation :

- La variable `type_logement_source` est **hautement discriminante** pour prédire la consommation et la classe DPE.
 - Elle servira aussi à **stratifier l'échantillon** lors de l'entraînement du modèle afin de bien distinguer les comportements "neuf" vs "ancien".
 - Ces résultats appuient la pertinence d'un futur **modèle différencié** ou d'un **feature engineering par type de logement** pour améliorer la précision.
-

Analyse par type de bâtiment

```
In [10]: plt.figure(figsize=(10,5))
sns.boxplot(x="type_batiment", y="conso_5_usages_ep", data=df)
plt.title("Consommation énergétique par type de bâtiment")
plt.xticks(rotation=45)
plt.show()
```



Interprétation – Consommation énergétique par type de bâtiment

Les maisons individuelles présentent une consommation énergétique médiane plus élevée que les appartements ou les immeubles collectifs.

Cette différence s'explique par :

- des volumes chauffés plus importants (surface et hauteur sous plafond supérieures),
- des pertes thermiques plus fortes en raison du nombre de façades exposées,
- et souvent des systèmes de chauffage moins efficaces.

Les appartements affichent la consommation la plus faible, profitant de la mutualisation des parois et d'une densité énergétique plus favorable.

Les immeubles collectifs ont une consommation intermédiaire, reflétant une diversité de tailles et de systèmes de chauffage.


Implications pour la modélisation :

- Le `type_batiment` est une variable catégorielle explicative importante à inclure dans le modèle de prédiction.
 - Cette variable capture des facteurs structurels (surface, isolation, type de chauffage collectif/individuel) qui influencent directement la consommation.
 - Dans la phase de modélisation, il pourra être pertinent de créer des interactions entre `type_batiment` et `surface_habitable_logement` pour mieux représenter ces effets combinés.
-

Corrélations entre variables numériques

```
In [11]: plt.figure(figsize=(12,10))
corr = df.select_dtypes(include=np.number).corr()
sns.heatmap(corr, cmap="coolwarm", center=0, annot=False)
plt.title("Matrice de corrélation (variables numériques)")
plt.show()

# Les plus fortes corrélations
corr_pairs = corr["conso_5_usages_ep"].sort_values(ascending=False)
print(corr_pairs.head(10))
```



	conso_5_us	emission_ges_5	cout_total_5	code_rec	conso_refroidissei	coordonnee_cartographiqu	inerti	conso	annee_con	nombre_niveau_li	vers	code_departem	surface_habitable_li	hauteur_sous	conso_chau	isolatio	coordonnee_cartographiqu	code_po	emission_ges_cl
conso_5_usages_ep	1.000000																		
conso_chauffage_ep	0.981155																		
cout_total_5_usages	0.942142																		
surface_habitable_logement	0.606880																		
emission_ges_chauffage	0.601725																		
emission_ges_5_usages	0.590564																		
conso_ecs_ep	0.487338																		
isolation_toiture	0.282396																		
hauteur_sous_plafond	0.136740																		
code_postal_ban	0.132117																		

Name: conso_5_usages_ep, dtype: float64

Interprétation – Corrélations entre variables numériques

La matrice de corrélation met en évidence plusieurs relations fortes et cohérentes entre les variables énergétiques :

- `conso_5_usages_ep` est fortement corrélée avec `emission_ges_5_usages` et `cout_total_5_usages`, ce qui confirme la cohérence physique entre consommation, émissions et coût énergétique.
- `conso_chauffage_ep` contribue également fortement à la consommation totale, ce qui reflète le poids du chauffage dans la performance énergétique globale.
- Les variables liées à la géolocalisation (`code_region_ban`, `code_departement_ban`, coordonnées) présentent des corrélations faibles, ce qui suggère que la localisation a un impact limité à l'échelle du département 69.
- La corrélation légèrement négative entre `annee_construction` et la consommation confirme que les bâtiments récents consomment moins.

Implications pour la modélisation :

- Les variables **hautement corrélées entre elles** (ex. consommation, GES, coût) doivent être **sélectionnées avec précaution** pour éviter la **multicolinéarité** dans certains modèles linéaires.
 - `conso_chauffage_ep`, `surface_habitable_logement`, `annee_construction` et `type_batiment` apparaissent comme des **features explicatives** majeures de la performance énergétique.
 - Ce graphique valide la **cohérence structurelle du dataset** : pas d'incohérence entre grandeurs physiques, et corrélations logiques selon le comportement attendu des bâtiments.
-

Visualisation interactive (Plotly)

```
In [51]: fig = px.scatter(
    df, x="surface_habitable_logement", y="conso_5_usages_ep",
    color="etiquette_dpe",
    hover_data=["type_batiment", "annee_construction"],
    title="Consommation vs Surface (par classe DPE)"
)

# Affichage classique dans Jupyter
fig.show()

# Export statique compatible avec nbconvert
fig.write_html("plot_conso_surface.html", include_plotlyjs='cdn')
```

Interprétation – Relation entre la surface et la consommation (par classe DPE)

Ce graphique interactif met en évidence une **corrélation positive** entre la surface du logement et la consommation énergétique totale : plus un logement est grand, plus sa consommation en kWhEP/an augmente.

Cependant, cette augmentation n'est pas strictement linéaire : les logements de grande taille peuvent afficher des consommations variées selon leur **classe DPE** et leur **année de construction**.

On distingue clairement des bandes colorées :

- Les classes **A–B** (en bas du graphique) consomment peu, même pour des surfaces importantes.
- Les classes **E–G** (en haut) présentent des consommations élevées, quel que soit le type de bâtiment.

- Les points les plus récents (visibles via le survol) appartiennent majoritairement aux classes **A–C**, confirmant l’effet des normes thermiques récentes.

Implications pour la modélisation :

- La relation entre `surface_habitable_logement` et `conso_5_usages_ep` est **forte et non linéaire**, ce qui justifie l’utilisation d’un modèle capable de capturer des effets complexes (ex. Random Forest ou Gradient Boosting).
 - Le **couplage des variables** `surface_habitable_logement`, `etiquette_dpe` et `annee_construction` sera déterminant pour prédire la consommation énergétique.
 - Cette visualisation confirme la **cohérence énergétique du dataset** et peut servir de base à une visualisation interactive dans Streamlit pour l’utilisateur final.
-

KPI récapitulatifs

```
In [13]: kpi = {
    "nb_logements": len(df),
    "conso_moyenne": round(df["conso_5_usages_ep"].mean(), 2),
    "emission_moyenne": round(df["emission_ges_5_usages"].mean(), 2),
    "surface_moyenne": round(df["surface_habitable_logement"].mean(), 2),
    "annee_moyenne_construction": round(df["annee_construction"].mean())
}
pd.DataFrame([kpi])
```

```
Out [13]:
```

	nb_logements	conso_moyenne	emission_moyenne	surface_moyenne	annee_moyenne_construction
0	427661	12503.64	1512.36	65.54	1982

Interprétation – Indicateurs clés du dataset

Ces indicateurs donnent une vision synthétique du parc de logements étudié dans le département 69 :

Indicateur	Valeur	Interprétation
Nombre total de logements	427 661	Taille importante du jeu de données, représentative du territoire étudié.
Consommation moyenne	12 503 kWhEP/an	Niveau de consommation globalement modéré, cohérent avec un parc mixte entre logements anciens et récents.
Émissions moyennes	1 512 kgCO ₂ /an	Confirme une performance énergétique moyenne, alignée avec la distribution observée des classes DPE (C–D dominantes).
Surface moyenne	65,5 m ²	Taille typique d'un logement en zone urbaine (appartements majoritaires).
Année moyenne de construction	1982	Indique que le parc est majoritairement composé de bâtiments construits avant les grandes réglementations thermiques modernes (RT2005, RT2012).

Implications pour la modélisation :

- Les moyennes sont cohérentes avec les tendances observées dans les analyses précédentes.
- Le modèle devra tenir compte de la **variabilité temporelle** (avant/après 2000) et du **type de logement** pour prédire précisément la consommation ou la classe DPE.
- Ces KPI serviront de **valeurs de référence** dans le futur tableau de bord Streamlit, permettant de comparer un logement individuel aux moyennes départementales.

Géospatial

```
In [20]: from pyproj import Transformer

# Création du transformateur Lambert-93 → WGS84
transformer = Transformer.from_crs("EPSG:2154", "EPSG:4326", always_xy=True)

# Application de la transformation
df["lon"], df["lat"] = transformer.transform(
    df["coordonnee_cartographique_x_ban"].values,
    df["coordonnee_cartographique_y_ban"].values
```



```
)

# Vérif rapide
print(df[["lon", "lat"]].head())
```

```
      lon      lat
0  4.399437  46.228788
1  4.448309  46.193515
2  4.502530  46.266415
3  4.480870  46.279810
4  4.435862  46.182965
```

In [50]: `import plotly.express as px`

```
df_geo = df.dropna(subset=["lat", "lon", "etiquette_dpe"])

fig = px.scatter_map(
    df_geo.sample(5000),
    lat="lat",
    lon="lon",
    color="etiquette_dpe",
    size="surface_habitable_logement",
    color_discrete_sequence=px.colors.qualitative.Vivid,
    zoom=8,
    map_style="carto-positron",
    title="Répartition géographique des logements par classe DPE (département 69)",
    hover_data={
        "nom_commune_ban": True,
        "conso_5_usages_ep": True,
        "etiquette_dpe": True,
        "annee_construction": True
    }
)

fig.update_layout(
    width=1600,
    height=700,
    margin=dict(l=0, r=0, t=40, b=0)
)

fig.show()
```